

BantuVoice

Architecture Technique — Documentation Complète

Pipeline de données linguistiques africaines souveraines
Collecte automatisée · Transcription IA · Validation humaine

Porteurs	Gildas & Aryad — Pôle Technique & Innovation
Institution	CSGR-IA — csgria.ga
Validation	M. Anguilet — Responsable Pôle (accordée, juin 2026)
Version	Document interne v1.0
Date	Juin 2026

1. Contexte et Genèse du Projet

BantuVoice est une initiative portée par le Pôle Technique & Innovation du CSGR-IA visant à construire la première infrastructure souveraine de données linguistiques africaines, en commençant par les langues gabonaises. Le constat de départ est simple et décisif : 88 % des langues africaines sont absentes des systèmes d'IA mondiaux. Les langues gabonaises n'existent dans aucun modèle existant — Whisper ne comprend pas le Fang, GPT ne parle pas Punu. Ce n'est pas une limitation technologique, mais une absence de données structurées.

L'insight fondateur du projet réside dans la nature orale des traditions africaines : la matière première existe déjà sous forme audio, disponible en qualité professionnelle sur des plateformes accessibles comme YouTube. BantuVoice propose de transformer cet audio en corpus exploitables, au format standard Hugging Face, prêts à entraîner des modèles de traitement automatique du langage.

2. Vue d'Ensemble de l'Architecture Technique

L'architecture de BantuVoice repose sur un pipeline en trois étapes complémentaires, combinant automatisation industrielle et expertise humaine. Chaque étape est conçue pour être progressive, documentée et reproductible sur de nouvelles langues. Le pipeline est conçu selon les principes suivants :

- Modularité** : chaque composante peut évoluer ou être remplacée indépendamment.
- Reproductibilité** : chaque décision technique est documentée pour permettre l'extension à d'autres langues.

- **Souveraineté** : les données produites restent sous contrôle africain, publiées sous licence souveraine.
- **Interopérabilité** : les formats de sortie respectent les standards internationaux (Hugging Face Datasets).

2.1 Flux Global du Pipeline



3. Étape 01 — Collecte Automatisée

3.1 Rôle dans le Pipeline

La phase de collecte est le point d'entrée du pipeline. Elle a pour mission de récupérer les données audio brutes depuis les sources en ligne et les archives locales, d'organiser ces données de manière structurée et indexée par langue, et de produire les métadonnées associées à chaque fichier audio (source, langue identifiée, durée, date de publication, etc.).

3.2 Outil Principal : yt-dlp

yt-dlp est un outil open source de téléchargement de contenu multimédia, fork avancé de youtube-dl. Il constitue le moteur principal de la collecte automatisée dans BantuVoice.

Caractéristique	Détail
Type	Outil CLI open source (Python)
Formats supportés	MP3, M4A, WAV, OPUS, OGG — extraction audio uniquement possible
Qualité audio	Téléchargement du flux audio natif (sans réencodage si possible)
Métadonnées	Extraction automatique : titre, description, date, durée, langue
Gestion des playlists	Téléchargement de chaînes entières ou playlists avec indexation
Robustesse	Gestion des reprises, des erreurs réseau, des contenus géo-restreints

3.3 Source Pilote : Dumwénu TV

La chaîne YouTube Dumwénu TV constitue la source pilote idéale pour BantuVoice. Cette chaîne est entièrement dédiée à la préservation et à la valorisation des langues et cultures nationales du Gabon.

Critère	Valeur
Langues couvertes	Fang · Punu · Obamba · Massangu · Gisir · Téké
Volume estimé	Plus de 300 heures d'audio exploitable disponibles immédiatement
Qualité	Enregistrements en qualité studio, contenu structuré par langue

3.4 Sources Complémentaires

Au-delà de Dumwénu TV, le pipeline de collecte est conçu pour intégrer d'autres sources :

- **Archives orales locales** : enregistrements d'institutions culturelles, de radios nationales, d'ONG.
- **Collections universitaires** : données linguistiques préexistantes dans les universités gabonaises.
- **Contributions communautaires** : enregistrements réalisés directement par des locuteurs natifs via un protocole de collecte participative.

3.5 Structure des Métadonnées

Chaque fichier audio collecté est associé à un fichier JSON de métadonnées structuré incluant les champs suivants :

Champ	Description
source_id	Identifiant unique de la source (ex. : dumwenu_tv_001)
language_code	Code de langue standardisé (ex. : fang, punu, obamba)
audio_path	Chemin relatif vers le fichier audio
duration_seconds	Durée totale de l'enregistrement en secondes
publication_date	Date de publication de la vidéo source
channel_name	Nom de la chaîne ou de la source
quality_flag	Indicateur de qualité audio (good / medium / low)
collection_date	Date de collecte par le pipeline

3.6 Output de l'Étape 01

- Fichiers audio bruts indexés, organisés par langue et par source
- Fichiers de métadonnées JSON associés à chaque enregistrement
- Journal de collecte (log) documentant les téléchargements réussis, échoués et les doublons détectés

4. Étape 02 — Transcription Automatique par IA

4.1 Rôle dans le Pipeline

La phase de transcription transforme les fichiers audio bruts en texte, produisant des paires audio-texte alignées au niveau du mot. C'est le cœur computationnel du pipeline. Son output constitue la matière première soumise à la validation humaine en étape 3.

4.2 Outil Principal : Whisper large-v3

Whisper est un modèle de reconnaissance automatique de la parole (ASR) développé par OpenAI, entraîné sur 680 000 heures d'audio multilingue. La version large-v3 est retenue pour BantuVoice en raison de ses meilleures performances sur les langues à faibles ressources.

Paramètre	Valeur / Configuration BantuVoice
Modèle	openai/whisper-large-v3
Tâche	transcribe (transcription dans la langue source)
Alignement	word-level timestamps via WhisperX ou forced alignment (wav2vec2)

Détection de langue	Automatique — mode de confirmation possible pour contrôle qualité
Format de sortie	JSON avec segments horodatés + texte brut .txt
Batch processing	Possible par lots (batched inference) pour optimiser les ressources GPU
Environnement	Python 3.10+, PyTorch, transformers, whisperx

4.3 Architecture du Signal Audio

Avant la transcription, chaque fichier audio passe par un pipeline de prétraitement du signal dont Aryad est responsable. Ce pipeline inclut les étapes suivantes :

- **Normalisation du volume** : standardisation des niveaux audio pour homogénéiser les sources.
- **Réduction du bruit** : filtrage des bruits de fond ambiant pour améliorer la précision de transcription.
- **Segmentation** : découpage automatique en segments de durée optimale (≤ 30 secondes) pour Whisper.
- **Détection de silences** : identification et suppression des segments sans contenu linguistique.
- **Contrôle qualité audio** : score de qualité attribué à chaque segment (SNR, clarté spectrale).

4.4 Protocole de Gestion des Langues à Faibles Ressources

Whisper a été entraîné principalement sur des langues à fortes ressources. Pour les langues gabonaises, des ajustements spécifiques sont nécessaires :

- **Forçage de la langue** : spécification explicite de la langue cible pour éviter les confusions avec des langues proches.
- **Chunking adaptatif** : segmentation fine pour compenser les erreurs d'alignement sur des phonèmes rares.
- **Prompt engineering** : injection de tokens de contexte en début de transcription pour guider le modèle.
- **Seuils de confiance** : filtrage des transcriptions avec score de confiance inférieur à un seuil défini (ex. : < 0.6 flagué pour révision prioritaire).

4.5 Format de Sortie — Paires Audio-Texte

L'output de la transcription est structuré en paires audio-texte alignées au mot près. Chaque segment produit :

Champ	Type	Description
audio_id	string	Identifiant unique du segment audio
language	string	Code de langue (ex. : fang)
audio_file	string	Chemin vers le fichier audio segmenté
transcript_raw	string	Texte brut produit par Whisper
word_timestamps	array	Liste [{word, start, end, confidence}]
confidence_score	float	Score de confiance global du segment (0.0–1.0)
whisper_model	string	Version de Whisper utilisée
processing_date	string	Date et heure de transcription (ISO 8601)
review_flag	boolean	True si le segment nécessite révision prioritaire

4.6 Output de l'Étape 02

- Transcriptions brutes en format JSON (paires audio-texte alignées mot par mot)
- Fichiers .txt de transcription brute par segment
- Tableau de bord de métriques (score de confiance moyen par langue, taux de segments flagués)

5. Étape 03 — Validation par Locuteurs Natifs

5.1 Rôle dans le Pipeline

La validation est l'étape qui transforme des transcriptions automatiques brutes en données scientifiquement valides. Elle garantit la qualité linguistique du corpus et constitue la valeur ajoutée humaine irremplaçable du projet. Sans cette étape, les données ne seraient pas fiables pour l'entraînement de modèles.

5.2 Interface Web d'Annotation

Une interface web dédiée est développée pour faciliter le travail des annotateurs. Elle est construite avec la stack suivante :

Couche	Technologie	Rôle
Frontend	React.js	Interface utilisateur des annotateurs — écoute audio + édition texte
Backend API	Python (FastAPI)	Gestion des segments, attribution des tâches, stockage
Base de données	MongoDB	Stockage des annotations, versions, scores de confiance
Authentification	JWT tokens	Gestion des accès annotateurs / superviseurs
Hébergement	VPS ou cloud souverain	Déploiement de l'interface d'annotation

5.3 Protocole de Double Annotation

BantuVoice adopte un protocole de double annotation pour garantir la qualité scientifique du corpus. Ce protocole fonctionne ainsi :

- **Attribution** : chaque segment est assigné indépendamment à deux annotateurs natifs différents.
- **Annotation indépendante** : chaque annotateur écoute le segment et corrige la transcription Whisper sans voir le travail de l'autre.
- **Calcul de l'accord inter-annotateurs** : le système calcule automatiquement le score d'accord (WER — Word Error Rate entre les deux annotations).
- **Résolution des conflits** : les segments avec désaccord significatif (WER > seuil défini) sont soumis à un troisième annotateur ou à un superviseur linguiste.
- **Validation finale** : les segments validés avec accord suffisant entrent dans le corpus final.

5.4 Métriques de Qualité

Le protocole de validation intègre plusieurs métriques de contrôle qualité :

Métrique	Définition	Seuil BantuVoice
WER (Word Error Rate)	Taux d'erreur mot entre transcription Whisper et annotation humaine	< 30% pour validation directe

IAA (Inter-Annotator Agreement)	Score d'accord entre les deux annotateurs d'un même segment	> 85% pour acceptation sans arbitrage
Confidence Score	Score de confiance moyen de Whisper sur le segment	< 0.6 → révision prioritaire
SNR (Signal-to-Noise Ratio)	Ratio signal/bruit du segment audio	< 15 dB → exclusion ou signalement

5.5 Recrutement et Gestion des Annotateurs

Le réseau d'annotateurs est un actif stratégique du projet. Le recrutement repose sur les réseaux des membres du pôle, notamment les profils linguistiques et culturels. Chaque annotateur suit un protocole d'intégration incluant :

- Formation aux outils d'annotation et à l'interface web
- Calibration initiale sur des segments de référence (gold standard)
- Attribution d'un identifiant anonymisé pour le suivi qualité
- Rémunération ou reconnaissance définie selon les modalités du projet

5.6 Output de l'Étape 03

- Corpus audio-texte validé, format Hugging Face Datasets (.parquet + README card)
- Scores de qualité par segment et par langue
- Documentation méthodologique du protocole de validation

6. Format de Sortie Final — Standard Hugging Face

6.1 Structure du Dataset

Le corpus final est publié au format Hugging Face Datasets, standard de facto pour les corpus de NLP et de reconnaissance vocale. Cette compatibilité assure une intégration directe dans les pipelines d'entraînement de modèles.

- **Format des données** : Apache Parquet, colonne par feature (audio, transcription, langue, métadonnées).
- **Dataset card** : README.md standardisé (description, langues, licence, statistiques, usage).
- **Splits standards** : train / validation / test avec ratio recommandé 80/10/10.
- **Licence** : Licence africaine souveraine open source (à définir — ex. Creative Commons BY-SA avec clause de souveraineté).
- **Hébergement** : Dépôt public sur Hugging Face Hub sous l'organisation CSGR-IA.

6.2 Compatibilité et Cas d'Usage

Le format de sortie est conçu pour alimenter directement les usages suivants :

- Fine-tuning de Whisper sur les langues gabonaises
- Entraînement de modèles de reconnaissance vocale dédiés
- Entraînement de modèles de traduction automatique
- Création de modèles de synthèse vocale (TTS) en langues locales
- Recherche académique en linguistique computationnelle

7. Stack Technologique Complète

Récapitulatif de l'ensemble des technologies utilisées dans le pipeline BantuVoice :

Composante	Technologie	Étape	Rôle
Collecte audio	yt-dlp	01	Téléchargement automatisé depuis YouTube
Stockage données	Système de fichiers structuré	01-03	Organisation des fichiers audio et métadonnées
Prétraitement audio	librosa / ffmpeg	02	Normalisation, segmentation, filtrage bruit
Transcription ASR	Whisper large-v3	02	Reconnaissance automatique de la parole
Alignement mot	WhisperX / wav2vec2	02	Horodatage au niveau du mot
Interface annotation	React.js	03	Frontend web pour les annotateurs natifs
API backend	Python / FastAPI	03	Gestion des tâches et des données
Base de données	MongoDB	03	Stockage des annotations et versions
Format corpus final	Hugging Face Datasets	03	Publication et distribution du corpus
Langage principal	Python 3.10+	01-03	Pipeline de traitement end-to-end
Gestion des dépendances	pip / conda	01-03	Environnements reproductibles
Versioning	Git + DVC	01-03	Versioning code et données

8. Organisation Technique de l'Équipe

La force de BantuVoice repose sur la complémentarité des profils déjà présents au sein du pôle. Chaque module est attribué selon les expertises disponibles :

Membre	Profil	Modules techniques	Disponibilité
Gildas	Développeur IA, projets ML actifs	Pipeline collecte (yt-dlp) Interface annotation (React) Coordination générale MVP end-to-end	Disponible immédiatement
Aryad	Calcul scientifique, analyse statistique	Architecture signal audio Prétraitement (librosa/ffmpeg) Protocole scientifique Modélisation statistique	À confirmer selon disponibilité
Membres volontaires du pôle	Linguistes, juristes, développeurs	Validation linguistique Recrutement locuteurs natifs Relectures scientifiques Protocole qualité	À identifier lors du kick-off
M. Anguilet	Responsable Pôle — supervision	Validation stratégique Portage institutionnel Relations avec bailleurs	Bénédiction accordée ✓

9. Roadmap Technique Détaillée

Jalon	Échéance	Livrables techniques	Responsable
Kick-off groupe de travail	Juin 2026	Constitution de l'équipe Validation de la roadmap Setup environnement de développement	Gildas + Aryad + pôle
MVP technique	Fin juillet 2026	Pipeline collecte opérationnel (yt-dlp) Transcription Whisper fonctionnelle 50 segments annotés en Fang Interface annotation v0.1	Gildas + Aryad
Corpus pilote v1	Fin août 2026	50h audio annotées (1 langue) Documentation scientifique complète Dépôt Hugging Face public Protocole qualité finalisé	Groupe de travail complet
Soumission bailleur	Sept-Oct 2026	Dossier technique UNESCO / AFD Rapport scientifique CSGR-IA Première publication ou preprint	M. Anguilet + porteurs
Phase croissance	2027	6 langues gabonaises couvertes 500h de données validées API BantuVoice v1 Modèle Whisper fine-tuné Fang	Équipe élargie

10. Principes Directeurs Techniques

Open source par défaut : L'intégralité du code du pipeline (collecte, transcription, interface d'annotation) est publiée en open source sous licence africaine souveraine. Cela favorise la reproductibilité, l'adoption par d'autres institutions africaines et la contribution externe.

Documentation systématique : Chaque décision technique et méthodologique est documentée au fur et à mesure. L'objectif est qu'une équipe externe puisse reproduire le pipeline sur une nouvelle langue africaine en suivant la documentation de BantuVoice.

Autonomie par module : Les trois étapes du pipeline fonctionnent de manière indépendante. Un problème sur la collecte n'empêche pas le travail sur l'interface d'annotation. Cette architecture modulaire évite les blocages et permet le travail parallèle.

Souveraineté des données : Les corpus produits restent sous contrôle du CSGR-IA et de la communauté gabonaise. Aucun accord d'exclusivité avec des acteurs étrangers ne peut être conclu sans validation institutionnelle explicite. Les données appartiennent à l'Afrique.

Scalabilité continentale : L'architecture est conçue dès le départ pour s'étendre à d'autres langues africaines au-delà du Gabon. Les langues cibles initiales (Fang, Punu, etc.) servent de preuve de concept d'un système généralisable à l'ensemble des 2000+ langues africaines.