

BantuVoice

Cadre Méthodologique et Scientifique

Structuration d'un projet de recherche publiable en NLP pour langues africaines
à faibles ressources — Protocole · Méthodologie · Évaluation · Éthique

Nature du document	Cadre méthodologique & scientifique — Document interne v1.0
Porteurs	Gildas & Aryad — Pôle Technique & Innovation, CSGR-IA
Institution	CSGR-IA — csgria.ga
Validation	M. Anguilet — Responsable Pôle
Ancrage disciplinaire	NLP · Speech Processing · Linguistique computationnelle · Data Sovereignty
Date	Juin 2026

1. Positionnement Épistémologique du Projet

Avant de définir un protocole, un projet de recherche scientifique doit établir sa position épistémologique — c'est-à-dire la façon dont il produit de la connaissance, ce qu'il revendique comme vrai, et dans quel cadre il s'inscrit. Pour BantuVoice, ce positionnement est double et indissociable : empiriste et décolonial.

1.1 Une Science Empiriste des Données

BantuVoice s'inscrit dans le paradigme des sciences empiriques des données. La connaissance produite est fondée sur des observations collectées, mesurables et reproductibles. Cela implique des engagements épistémiques précis :

- Falsifiabilité** : les affirmations du projet (qualité du corpus, performance des modèles) sont testables et réfutables par des tiers.
- Reproductibilité** : l'intégralité du pipeline (code, paramètres, protocoles) est publiée pour permettre la réplication indépendante des résultats.
- Traçabilité** : chaque décision méthodologique est documentée avec sa justification, permettant un audit scientifique complet.

- **Incertitude assumée** : les limites du corpus (biais de source, couverture dialectale, taille) sont explicitement déclarées — pas dissimulées.

1.2 Un Paradigme de Recherche Participative Décoloniale

BantuVoice ne se contente pas de produire des données sur les langues gabonaises — il les produit avec et pour les communautés concernées. Ce positionnement s'inscrit dans le courant de la recherche participative décoloniale, théorisé dans le champ NLP africain notamment par Masakhane, dont le principe fondateur est :

« *Africans should be able to decide what data represents our communities globally, retain ultimate ownership of that data, and know how it is used.* »
 — *Principes de souveraineté des données, Masakhane (2020)*

Ce paradigme impose des contraintes méthodologiques concrètes : le consentement éclairé des locuteurs n'est pas optionnel, les communautés ont un droit de regard sur les usages des données, et la propriété intellectuelle du corpus reste africaine. C'est ce qui distingue BantuVoice d'une simple collecte de données : c'est un acte de souveraineté scientifique.

1.3 Contribution Originale Revendiquée

Pour être publiable, un projet doit formuler sa contribution originale — ce qu'il apporte que personne d'autre n'a produit. Pour BantuVoice, cette contribution est triple :

Dimension	Contribution originale de BantuVoice	Référence de comparaison
Géographique	Premier corpus audio structuré pour les langues du Gabon et d'Afrique centrale (zone CEMAC)	Masakhane (Afrique subsaharienne), NCHLT (Afrique du Sud)
Méthodologique	Pipeline hybride automatisé (yt-dlp + Whisper) + validation native, documenté et reproductible	Kallaama (Sénégal) — collecte manuelle terrain
Institutionnelle	Portage par une institution publique nationale (CSGR-IA) garantissant la souveraineté des données	NaijaVoices, WAXAL — portage communautaire ou privé
Linguistique	Documentation scientifique de langues non décrites dans les ressources NLP mondiales (Fang, Punu, Obamba, Gisir...)	CommonVoice — langues avec ressources existantes

2. Questions de Recherche et Hypothèses

Un article scientifique publiable dans une conférence de référence (LREC-COLING, INTERSPEECH, AfricaNLP@ACL) exige une ou plusieurs questions de recherche explicites, dont les réponses constituent la contribution du papier. BantuVoice en formule trois, de la plus fondamentale à la plus appliquée.

2.1 Questions de Recherche Principales

RQ1 — Faisabilité de la collecte automatisée

Dans quelle mesure un pipeline automatisé (yt-dlp + Whisper large-v3) permet-il de constituer un corpus audio-texte de qualité scientifique acceptable pour des langues gabonaises à faibles ressources, sans transcription manuelle initiale ?

RQ2 — Qualité de la transcription automatique sur langues non vues

Quel est le Word Error Rate (WER) de Whisper large-v3 sur les langues gabonaises, et dans quelle mesure la validation par locuteurs natifs réduit-elle ce taux à un niveau acceptable pour l'entraînement de modèles ASR ?

RQ3 — Reproductibilité et scalabilité du pipeline

Le pipeline BantuVoice est-il reproductible sur d'autres langues africaines par une équipe disposant de ressources comparables, et à quel coût humain et computationnel ?

2.2 Hypothèses Opérationnelles

À chaque question correspond une hypothèse falsifiable, qui sera confirmée ou infirmée par les résultats du projet :

Question	Hypothèse (H)	Condition d'invalidation
RQ1	H1 : Il est possible de constituer un corpus de 50h d'audio annoté en Fang avec un WER post-validation < 20% via le pipeline automatisé	WER post-validation > 30% malgré correction native
RQ2	H2 : Whisper large-v3 produit des transcriptions brutes exploitables (WER < 60%) sur au moins 4 langues gabonaises sans fine-tuning préalable	WER brut > 80% sur toutes les langues testées
RQ3	H3 : Le pipeline peut être reproduit sur une nouvelle langue bantoue par une équipe de 2 personnes en moins de 3 mois avec les mêmes outils	Temps de reproduction > 6 mois ou nécessite expertise supplémentaire non documentée

3. Revue de Littérature et Positionnement dans l'État de l'Art

Toute publication scientifique situe sa contribution dans le corpus existant. BantuVoice doit démontrer qu'il connaît ce qui a été fait, qu'il s'y appuie, et qu'il comble une lacune réelle. Voici l'état de l'art structuré.

3.1 Écosystème des Corpus Africains Existants

La recherche en NLP et ASR pour les langues africaines a produit plusieurs corpus de référence au cours des cinq dernières années. BantuVoice s'inscrit dans cet écosystème tout en adressant une zone géographique et linguistique inexplorée.

Corpus / Projet	Langues	Volume	Méthode	Pertinence pour BantuVoice
Masakhane (2020–)	54+ langues africaines	Variable	Participatif, open source	Modèle organisationnel et éthique de référence
NCHLT (Barnard et al.,	11 langues sud-africaines	4–10h / langue	Lecture de prompts	Standard méthodologique pour corpus ASR

2014)				
Kallaama (Gauthier et al., 2024)	Wolof, Pulaar, Sereer	100h+	Terrain + radio	Modèle collecte audio spontané en contexte agricole
WAXAL (2026)	Multilingue africain	Large-scale	Partenariats académiques	Référence la plus récente — à citer et se distinguer
CommonVoice (Mozilla)	90+ langues	Variable	Contribution communautaire	Standard de format de référence (à adopter)
ALFFA (Besacier & Gauthier)	Wolof, Fongbe, Swahili, Amharic	2–6h / langue	Pipeline automatisé + annotation	Méthodologie proche de BantuVoice — comparaison directe

3.2 Lacune Identifiée — La Zone CEMAC

L'analyse de la littérature révèle une lacune géographique et linguistique précise : aucun corpus scientifique publié ne couvre les langues de la zone Afrique centrale (Gabon, Cameroun, Congo, RDC, Tchad). Masakhane couvre principalement l'Afrique de l'Est et de l'Ouest ; NCHLT l'Afrique australe. La zone CEMAC est scientifiquement absente de la carte NLP africaine.

« Even in the forums which aim to widen NLP participation, Africa is barely represented — despite the fact that Africa has over 2000 languages. »
— Masakhane Research Foundation (2020)

BantuVoice est la première réponse institutionnelle à cette lacune depuis l'Afrique centrale.

3.3 Outils Technologiques — Littérature Pertinente

L'usage de Whisper pour la transcription de langues à faibles ressources est documenté dans la littérature récente. Les travaux de référence à citer dans une publication :

- **Radford et al. (2023)** : "Robust Speech Recognition via Large-Scale Weak Supervision" — papier original Whisper, OpenAI. À citer pour justifier le choix de Whisper large-v3.
- **Doumbouya et al. (2021)** : "Using Radio Archives for Low-Resource Speech Recognition" — démontre la faisabilité de l'extraction audio depuis des sources de diffusion pour des langues africaines.
- **Nakatumba-Nabende et al. (2024)** : "Building Text and Speech Benchmark Datasets for Low-Resourced East African Languages" — papier méthodologique de référence pour la structuration d'un corpus ASR africain publiable.
- **Bsharat et al. (2023)** : "Augmented Datasheets for Speech Datasets and Ethical Decision-Making" — cadre éthique pour la documentation de corpus audio, applicable à BantuVoice.

4. Design Méthodologique

Le design méthodologique est le cœur du cadre scientifique. Il décrit avec précision comment les données sont collectées, traitées et validées — de manière à ce que les choix soient justifiés, reproductibles et critiquables. C'est ce qui distingue un projet technique d'une recherche scientifique.

4.1 Paradigme Méthodologique Général

BantuVoice adopte une méthodologie mixte séquentielle, combinant :

- **Approche quantitative** : mesures objectivées — WER, IAA (Cohen's Kappa), SNR, volume en heures, distribution des locuteurs. Ces métriques permettent la comparaison avec d'autres corpus africains.
- **Approche qualitative** : validation linguistique par des experts natifs, documentation des choix orthographiques, des variantes dialectales, des difficultés de transcription spécifiques à chaque langue.
- **Recherche-action participative** : les communautés de locuteurs sont parties prenantes actives du processus, pas simplement sujets de la recherche. Le design du projet leur est soumis pour validation.

4.2 Critères de Sélection des Sources (Sampling Design)

La représentativité du corpus repose sur des critères de sélection explicites et défendables. Les sources sont sélectionnées selon les critères suivants :

Critère	Spécification	Justification scientifique
Langue cible	Fang, Punu, Obamba, Massangu, Gisir, Téké — phase pilote	Langues à locuteurs > 50 000 au Gabon, non représentées dans aucun corpus existant
Qualité audio minimale	SNR ≥ 15 dB, fréquence d'échantillonnage ≥ 16 kHz	Seuil minimal pour Whisper — documenté dans Radford et al. (2023)
Type de discours	Discours spontané + discours préparé (80/20)	Représentativité de l'usage réel de la langue — éviter le biais de lecture
Diversité des locuteurs	Minimum 10 locuteurs distincts / langue, parité genre visée	Standard NCHLT — nécessaire pour généralisation des modèles
Accessibilité juridique	Contenu sous licence Creative Commons ou consentement explicite	Conformité éthique et légale — condition de publication
Diversité géographique	Locuteurs de zones urbaines et rurales	Capturer la variation dialectale — standard de qualité corpus

4.3 Protocole de Collecte — Procédures Standardisées

4.3.1 Collecte automatisée (Sources en ligne)

- **Identification** : inventaire systématique des sources YouTube par langue cible — critères d'inclusion documentés dans un registre de sources.
- **Extraction** : yt-dlp avec paramètres fixes (format audio : WAV 16kHz mono, métadonnées : JSON, journalisation complète des erreurs).
- **Contrôle de qualité initial** : filtrage automatique par SNR < 15 dB et durée < 5 secondes (exclusion documentée).

- **Segmentation** : découpage en segments de 3–30 secondes par détection de silences (WebRTC VAD ou librosa).
- **Indexation** : attribution d'un identifiant unique par segment (format : BV-[LANGUE]-[SOURCE]-[NUMÉRO]).

4.3.2 Collecte terrain (Réseau de locuteurs natifs)

- **Recrutement** : via le réseau des jeunes formés CSGR-IA et les membres linguistes du pôle — critère d'inclusion : locuteur natif confirmé par auto-déclaration et validation croisée.
- **Environnement d'enregistrement** : protocole standardisé — pièce calme, microphone à moins de 30 cm, durée 5–15 minutes par session.
- **Contenu** : liste de prompts standardisés (500 phrases par langue) + discours libre guidé (10 minutes) — équilibre lecture / spontané.
- **Consentement** : formulaire de consentement éclairé signé, en français et dans la langue du locuteur si possible — archivé séparément des données.
- **Remontée** : upload via interface sécurisée avec formulaire de métadonnées (identité anonymisée, langue, zone géographique, âge, genre).

4.4 Protocole de Transcription et d'Alignement

La transcription automatique est traitée comme une hypothèse à valider, pas comme une vérité — ce positionnement est fondamental pour la rigueur scientifique du projet.

- **Transcription brute** : Whisper large-v3 avec forçage de langue — paramètres fixes documentés (température, beam size, language token).
- **Alignement force** : WhisperX pour l'alignement au niveau du mot (word-level timestamps) — modèle wav2vec2 utilisé documenté par langue.
- **Calcul du score de confiance** : score de confiance Whisper extrait par segment et par mot — distribué dans le dataset.
- **Segmentation finale** : découpage en unités de transcription (utterances) correspondant aux pauses naturelles.
- **Flagging automatique** : segments avec confidence score < 0.6 ou SNR < 15 dB marqués pour révision prioritaire.

4.5 Protocole de Validation — Double Annotation Contrôlée

La validation est l'étape qui donne sa valeur scientifique au corpus. Elle doit être documentée avec suffisamment de précision pour être reproductible.

Phase	Procédure	Outil	Output mesuré
Sélection annotateurs	Locuteurs natifs, formation de 2h sur l'interface et le protocole, calibration sur 20 segments de référence	Interface web React + guide annotateur	Score de calibration ≥ 0.75 Kappa requis
Annotation indépendante	Chaque segment assigné à 2 annotateurs distincts — sans accès à la transcription de l'autre	Interface web — affichage audio + texte Whisper éditable	Transcription corrigée par chaque annotateur
Calcul IAA	Cohen's Kappa calculé automatiquement entre les 2 annotations sur chaque segment	Script Python automatisé	Kappa > 0.80 = accord fort / 0.60–0.80 = accord modéré

Résolution conflits	Kappa < 0.60 : soumis à arbitrage par superviseur linguiste — décision documentée	Interface superviseur dédiée	Annotation consensuelle finale + motif du désaccord
Validation finale	Segment intégré au corpus si Kappa ≥ 0.60 après arbitrage	Pipeline automatisé	WER final calculé vs Whisper brut

5. Cadre Éthique et Souveraineté des Données

La dimension éthique n'est pas un appendice d'un projet de corpus — c'est une condition de publication dans les conférences de référence. LREC-COLING, INTERSPEECH et AfricaNLP exigent tous une section éthique explicite. Pour BantuVoice, cette dimension est également constitutive de son identité scientifique.

5.1 Principes FAIR et CARE

BantuVoice s'engage sur deux cadres éthiques complémentaires pour les données de recherche :

Cadre	Principe	Application BantuVoice
FAIR (données de recherche)	Findable	Dépôt public sur Hugging Face Hub avec DOI permanent
	Accessible	Licence open source — téléchargement libre sans barrière institutionnelle
	Interoperable	Format Hugging Face Datasets (Parquet) — standard de facto NLP
	Reusable	Dataset card complète : description, langue, licence, limites, usage recommandé
CARE (données autochtones)	Collective Benefit	Le corpus bénéficie d'abord aux communautés gabonaises — applications locales prioritaires
	Authority to Control	Le CSGR-IA et les communautés conservent le droit de retrait ou de restriction d'usage
	Responsibility	Obligation de rendre compte aux communautés des usages effectifs des données
	Ethics	Consentement éclairé, anonymisation, droit à l'oubli garanti à chaque locuteur

5.2 Protocole de Consentement Éclairé

- **Information préalable** : chaque locuteur reçoit une explication claire des objectifs du projet, des usages prévus des données et de ses droits — dans la langue de son choix.
- **Consentement explicite** : formulaire signé ou enregistrement audio du consentement verbal, archivé séparément des données de recherche.

- **Droit de retrait** : tout locuteur peut demander la suppression de ses enregistrements à tout moment, y compris après publication du corpus.
- **Anonymisation** : les noms des locuteurs ne figurent pas dans les données publiées — identifiants anonymisés uniquement.
- **Usage délimité** : les données collectées ne peuvent être utilisées qu'à des fins de recherche NLP et de préservation linguistique — pas de finalité commerciale sans accord explicite.

5.3 Questions de Droits d'Auteur sur les Sources YouTube

L'utilisation de contenus YouTube soulève des questions juridiques que le projet doit adresser explicitement pour être publiable et défendable :

Situation	Traitement recommandé
Contenu sous licence CC (Creative Commons)	Utilisation directe autorisée — documenter la licence dans les métadonnées
Contenu avec copyright traditionnel (chaînes médias)	Contacteur le détenteur des droits pour accord de recherche — documenter l'accord
Contenu produit par des institutions publiques gabonaises	Vérifier statut de domaine public — privilégier ces sources
Contenu Dumwénu TV	Prendre contact avec la chaîne pour un accord de partenariat de recherche formel — valorisant pour eux aussi
En cas de doute	Ne pas intégrer dans le corpus public — utiliser uniquement pour le développement interne

Recommandation stratégique : un accord formel de partenariat avec Dumwénu TV, formalisé par le CSGR-IA, résout l'ensemble des questions de droits et constitue un actif institutionnel valorisable auprès des bailleurs. C'est un acte de diplomatie scientifique que le portage institutionnel du CSGR-IA rend possible là où une startup privée ne pourrait qu'espérer une tolérance.

6. Métriques d'Évaluation Scientifique du Corpus

Un corpus scientifique ne se définit pas seulement par son volume — il se définit par la rigueur avec laquelle sa qualité est mesurée et déclarée. Ces métriques permettent la comparaison avec d'autres corpus et constituent les résultats quantitatifs de la publication.

6.1 Métriques de Qualité Audio

Métrique	Définition	Seuil BantuVoice	Interprétation
SNR (Signal-to-Noise Ratio)	Ratio signal utile / bruit de fond en décibels	≥ 15 dB pour inclusion	< 15 dB → exclusion documentée ou annotation du bruit

MOS (Mean Opinion Score)	Score d'évaluation subjective de qualité audio par les annotateurs (1–5)	Cible ≥ 3.5	Standard télécommunications — comparable à d'autres corpus
Fréquence d'échantillonnage	Hz du signal audio	≥ 16 000 Hz	Minimum absolu pour Whisper et modèles ASR modernes
Durée par segment	Durée en secondes de chaque utterance	3–30 secondes	Optimal pour Whisper — segments trop courts ou longs dégradent la transcription

6.2 Métriques de Qualité de Transcription

Métrique	Formule / Définition	Usage dans BantuVoice
WER (Word Error Rate)	$WER = (S + D + I) / N$ (S=substitutions, D=suppressions, I=insertions, N=mots référence)	Mesure principale — calculé entre Whisper brut et annotation native finale
CER (Character Error Rate)	Même formule au niveau des caractères	Complémentaire au WER pour langues agglutinantes (Fang, Punu) où la morphologie est complexe
MER (Match Error Rate)	$MER = (S + D + I) / (H + S + D + I)$	Alternative au WER moins sensible aux insertions — à rapporter si WER anormalement élevé
Confidence Score Whisper	Score de probabilité moyen par segment produit par Whisper (0.0–1.0)	Proxy de difficulté de transcription par langue — corrélation avec WER à démontrer

6.3 Métriques d'Accord Inter-Annotateurs (IAA)

Métrique	Formule	Interprétation	Seuil publication
Cohen's Kappa (κ)	$\kappa = (Po - Pe) / (1 - Pe)$ Po = accord observé, Pe = accord attendu par chance	κ < 0.40 : faible 0.40–0.60 : modéré 0.60–0.80 : fort > 0.80 : quasi-parfait	> 0.60 requis > 0.75 recommandé
Fleiss's Kappa	Extension de Cohen pour > 2 annotateurs	Utilisé si 3 annotateurs ou plus sur un segment	> 0.60
WER inter-annotateurs	WER calculé entre les 2 transcriptions natives (sans référence Whisper)	Mesure directe du désaccord linguistique — indépendant de Whisper	< 15% idéalement

6.4 Métriques de Représentativité du Corpus

La qualité d'un corpus se mesure aussi à sa diversité — pour éviter les biais qui rendraient les modèles entraînés non généralisables :

- **Distribution genre** : ratio hommes/femmes parmi les locuteurs — cible 50/50, déclaré même si non atteint.
- **Distribution âge** : représentation de tranches d'âge (jeunes, adultes, seniors) — la langue varie selon l'âge.
- **Distribution géographique** : locuteurs urbains vs ruraux — variation dialectale significative au Gabon.
- **Distribution des types de discours** : ratio lecture guidée / discours spontané — documenté par segment.
- **Type-Token Ratio (TTR)** : mesure de richesse lexicale du corpus — indique si le vocabulaire est varié ou répétitif.

7. Documentation Scientifique — Dataset Card et Data Statement

La documentation du corpus est autant une exigence scientifique qu'une exigence éthique. Deux standards s'imposent dans la communauté NLP pour la documentation formelle d'un dataset : le Dataset Card (Hugging Face) et le Data Statement (Bender & Friedman, 2018).

7.1 Structure du Dataset Card (Hugging Face)

Le Dataset Card est le document de référence publié avec le corpus sur Hugging Face Hub. Il doit couvrir les sections suivantes, sans exception :

- **Dataset Summary** : Description en 2–3 phrases — langue(s), volume, méthode de collecte, usage principal.
- **Supported Tasks** : ASR (Automatic Speech Recognition), Language Identification, potentiellement TTS et NER.
- **Languages** : Codes BCP-47 pour chaque langue — créer des codes pour les langues gabonaises sans code standard.
- **Dataset Structure** : Schéma des champs (audio, transcription, langue, locuteur_id, durée, qualité...).
- **Dataset Creation** : Sources, procédure de collecte, annotations — référence à ce document méthodologique.
- **Annotations** : Type d'annotation (transcription orthographique), protocole de validation, IAA reporté.
- **Personal and Sensitive Information** : Anonymisation, consentement, données exclues.
- **Considerations for Using the Data** : Limites du corpus, biais identifiés, usages non recommandés.
- **Citation Information** : BibTeX du papier associé — à créer dès soumission du preprint ArXiv.

7.2 Data Statement (Standard Bender & Friedman 2018)

Le Data Statement est une pratique documentaire issue de la linguistique computationnelle exigeant une description explicite du contexte de production des données. Pour BantuVoice, les 8 dimensions du Data Statement sont :

Dimension	Contenu pour BantuVoice
CURATION RATIONALE	Motivation : combler l'absence totale de ressources NLP pour les langues gabonaises. Critères d'inclusion et d'exclusion explicites.
LANGUAGE VARIETY	Spécification des variétés linguistiques (dialectes, registres) couverts — et ceux exclus. Note sur les variantes non captées.
SPEAKER DEMOGRAPHIC	Distribution déclarée : genre, âge, zone géographique, statut de locuteur natif. Limites de représentativité.
SPEECH SITUATION	Contexte de production : discours spontané (Dumwénu TV), lecture guidée (terrain), conversation (si applicable).
TEXT CHARACTERISTICS	Type de contenu transcrit : discours oral spontané, présentation structurée, conversation informelle.
RECORDING QUALITY	Équipement, environnement, fréquence d'échantillonnage, SNR moyen reporté par source.
OTHER	Informations complémentaires spécifiques aux langues bantoues : tons, structure syllabique, morphologie agglutinante.
PROVENANCE APPENDIX	Tableau détaillé de chaque source avec URL, date d'accès, licence, volume extrait.

8. Stratégie de Publication Scientifique

Un projet de recherche sans stratégie de publication reste invisible. Pour le CSGR-IA, la publication est un vecteur de légitimité scientifique, de financement et de positionnement continental.

8.1 Typologies de Publications Ciblées

Type de publication	Cible / Conférence	Timing	Contenu principal
Paper de corpus (dataset paper)	LREC-COLING 2026 ou AfricaNLP @ ACL 2027	Après corpus pilote v1 (sept. 2026)	Description complète du corpus, métriques de qualité, baseline ASR
Preprint ArXiv	ArXiv cs.CL	Dès MVP fonctionnel (août 2026)	Version préliminaire — assurer la priorité scientifique sur la contribution
Paper système (system paper)	INTERSPEECH 2027	Après fine-tuning Whisper sur Fang	Résultats du modèle ASR fine-tuné — comparaison avec Whisper baseline
Rapport technique CSGR-IA	Publication institutionnelle csgria.ga	Sept-Oct 2026	Document interne public — fonder les dossiers bailleurs
Article de	Presse scientifique	Après	Rendre le projet visible dans

vulgarisation	africaine, blog CSGR-IA	preprint	l'écosystème continental
---------------	-------------------------	----------	--------------------------

8.2 Structure Standard d'un Dataset Paper (LREC / AfricaNLP)

Le papier de corpus de BantuVoice suivra la structure standard des dataset papers acceptés dans les conférences de référence :

- **Section 1 — Abstract (150 mots)** Problème, données produites, méthode, métriques clés, disponibilité.
- **Section 2 — 1. Introduction** Motivation — l'absence de ressources pour les langues gabonaises, contribution originale.
- **Section 3 — 2. Related Work** Revue des corpus africains existants (section 3 de ce cadre), positionnement différentiel.
- **Section 4 — 3. Data Collection** Pipeline yt-dlp, sources, critères de sélection, volume par langue.
- **Section 5 — 4. Data Processing** Whisper, alignement, segmentation, protocole de prétraitement audio.
- **Section 6 — 5. Annotation Methodology** Double annotation, IAA (Cohen's Kappa reporté), résolution des conflits.
- **Section 7 — 6. Corpus Analysis** Statistiques descriptives, distribution des locuteurs, analyse WER brut vs validé.
- **Section 8 — 7. Baseline Experiments** Fine-tuning Whisper sur sous-ensemble Fang — WER baseline à comparer.
- **Section 9 — 8. Ethical Considerations** Consentement, souveraineté, FAIR/CARE, limitations.
- **Section 10 — 9. Conclusion & Future Work** Bilan, extensions prévues (autres langues, API BantuVoice).

8.3 Conférences et Ateliers Cibles

Conférence / Atelier	Type	Deadline typique	Pertinence BantuVoice
AfricaNLP Workshop @ ACL	Atelier spécialisé NLP africain	Mars (pour juillet)	Première cible — communauté directement concernée
LREC-COLING	Conférence internationale ressources linguistiques	Octobre/novembre	Référence mondiale pour les dataset papers — haute visibilité
INTERSPEECH	Conférence internationale traitement de la parole	Mars (pour sept.)	Pour les résultats ASR post fine-tuning
RAIL Workshop (LREC)	Resources for African Indigenous Languages	Calé sur LREC	Atelier dédié — idéal pour 1ère publication
Lacuna Fund Report	Rapport de financement	Selon appel	Valorisation institutionnelle et financière

9. Gouvernance Scientifique du Projet

La rigueur scientifique n'est pas seulement une affaire de protocoles techniques — elle se construit aussi dans la gouvernance du projet : qui décide quoi, comment les conflits sont résolus, comment la connaissance est partagée.

9.1 Rôles Scientifiques Distincts

Rôle	Responsable	Responsabilités scientifiques spécifiques
Principal Investigator (PI)	Gildas	Intégrité du pipeline — garant de la reproductibilité — premier auteur du dataset paper
Co-Investigateur (Co-I) Signal	Aryad	Validité du protocole audio — responsable des métriques SNR, MOS, alignement
Superviseur Scientifique	M. Anguilet	Validation des choix méthodologiques — signature institutionnelle sur les publications
Experts Linguistiques	Membres pôle + linguistes externes	Définition des conventions orthographiques — arbitrage des désaccords d'annotation
Coordinateurs Communautaires	Jeunes formés CSGR-IA	Responsables terrain — garants de l'éthique locale et du protocole de consentement

9.2 Gestion de la Propriété Intellectuelle

- **Propriété du corpus** : le CSGR-IA détient la propriété collective du corpus en tant qu'institution — les locuteurs conservent des droits moraux sur leurs contributions.
- **Propriété du code** : open source sous licence MIT ou Apache 2.0 — attribution CSGR-IA obligatoire.
- **Politique d'auteur** : toute personne ayant contribué significativement (code, annotation, collecte, analyse) figure dans les auteurs ou les remerciements — documenté dès le début.
- **DOI et archivage** : chaque version du corpus reçoit un DOI permanent (via Zenodo ou Hugging Face) — versioning sémantique (v1.0, v1.1...).
- **Usage commercial** : toute utilisation commerciale des données par un tiers requiert un accord explicite avec le CSGR-IA — clause à intégrer dans la licence.

9.3 Registre de Recherche et Traçabilité

Un registre de recherche (research log) est tenu tout au long du projet, documentant :

- Toutes les décisions méthodologiques et leur justification
- Les expérimentations infructueuses (negative results — aussi importants scientifiquement)
- Les révisions du protocole avec date et motif
- Les incidents (données corrompues, annotateur défaillant, source supprimée)
- Les versions successives du pipeline avec leurs paramètres exacts

Principe fondamental : en science, une erreur documentée est scientifiquement utile. Une erreur dissimulée est une fraude. BantuVoice s'engage à publier ses résultats tels qu'ils sont — y compris les WER décevants ou les difficultés d'annotation — car c'est précisément ces résultats

10. Checklist de Rigueur Scientifique — Avant Soumission

Cette checklist synthétise les conditions minimales pour qu'une publication BantuVoice soit acceptée dans une conférence internationale de référence. Elle sert de guide d'auto-évaluation à chaque étape du projet.

Section Données

- Volume minimum déclaré : ≥ 10 h audio par langue (50h total pour la phase pilote)
- Nombre de locuteurs minimum : ≥ 10 locuteurs distincts par langue
- Distribution genre documentée et reportée
- SNR moyen reporté par source et par langue
- Critères d'exclusion des segments documentés avec statistiques
- Toutes les sources listées dans une table de provenance avec licence

Section Méthodologie

- Pipeline entièrement reproductible — code publié sur GitHub sous licence open source
- Paramètres Whisper exactement documentés (version, température, beam size, language token)
- Protocole d'annotation écrit et disponible en annexe ou en ligne
- Cohen's Kappa reporté par langue (pas seulement global)
- WER brut (Whisper) et WER post-validation reportés séparément pour chaque langue
- Exemples d'erreurs de transcription discutés et analysés

Section Éthique

- Consentement éclairé documenté pour tous les locuteurs natifs (collecte terrain)
- Statut juridique de chaque source en ligne vérifié et documenté
- Section Ethics Statement présente dans le papier
- Politique d'anonymisation des locuteurs décrite
- Droit de retrait documenté et mis en œuvre

Section Publication

- Preprint ArXiv soumis avant la conférence cible (priorité scientifique)
 - Dataset Card complète publiée sur Hugging Face Hub avec DOI
 - Data Statement (Bender & Friedman) inclus ou disponible en ligne
 - Code de reproduction publié avec README complet
 - Baseline ASR expérience reportée (même avec des résultats modestes)
 - Limitations du corpus explicitement déclarées dans le papier
-
-

