

BantuVoice

Initiative nationale de données linguistiques pour l'IA

Porteurs	Gildas & Aryad — Pôle Technique & Innovation, CSGR-IA
Destinataires	Membres du Pôle Technique & Innovation, CSGR-IA
Validation	M. Anguilet — Responsable Pôle (bénédiction accordée, juin 2026)
Date	Juin 2026
Nature	Note stratégique interne — Proposition de projet officiel CSGR-IA

Scale AI · pour l'Afrique · fait par l'Afrique · porté par le CSGR-IA

RÉSUMÉ EXÉCUTIF

BantuVoice est une proposition de projet officiel du CSGR-IA visant à construire la première infrastructure souveraine de données linguistiques africaines — en commençant par les langues gabonaises. C'est l'opportunité pour le CSGR-IA de passer du rôle consultatif au rôle de producteur de science, d'attirer des investisseurs étrangers, et de s'imposer comme référence continentale en NLP africain.

Le problème — 88% des langues africaines sont absentes de l'IA mondiale. Les langues gabonaises n'existent dans aucun modèle — Whisper ne comprend pas le Fang, GPT ne parle pas Punu. Non par manque de technologie, mais par manque de données structurées.

L'insight clé — La matière première existe déjà : des centaines d'heures d'audio professionnel en langues locales sont disponibles sur YouTube (ex : Dumwénu TV). Nos traditions sont orales — c'est là qu'est la donnée, pas dans le texte.

La solution — Un pipeline en 3 étapes : collecte automatisée (yt-dlp) → transcription IA (Whisper) → validation par locuteurs natifs. Un corpus exploitable, format standard Hugging Face, prêt à entraîner des modèles.

Pourquoi le CSGR-IA — Porter BantuVoice en projet officiel positionne le CSGR-IA comme premier producteur africain de données linguistiques souveraines — ce qui ouvre des financements étrangers (UNESCO, AFD, fondations) inaccessibles à une startup privée.

Prochaine étape — Constituer le groupe de travail au sein du pôle et déployer un MVP fonctionnel d'ici fin août 2026.

01 GENÈSE — COMMENT CE PROJET EST NÉ

Une conviction partagée au sein du pôle

BantuVoice est né d'une discussion entre membres du pôle Technique & Innovation. Le constat de départ : on ne peut pas parler d'IA sans données. Et si pour les grandes langues mondiales ces données existent, pour les langues gabonaises il n'y a rien — ou presque.

La réflexion a évolué : plutôt que de chercher à écrire nos langues — une tâche longue et complexe — pourquoi ne pas partir de ce qui existe déjà ? **Nos traditions sont orales. La donnée la plus naturelle, c'est l'audio.** Et cet audio existe, en qualité professionnelle, sur des plateformes accessibles.

L'approche a reçu l'aval de M. Anguilet qui a encouragé l'initiative en insistant sur les valeurs du comité : *liberté, autonomie, et la force des cerveaux complémentaires*. Ce document est le premier livrable concret de cette dynamique collective.

02 OPPORTUNITÉ STRATÉGIQUE POUR LE CSGR-IA

Ce projet n'est pas seulement pertinent techniquement — il est stratégiquement décisif pour le positionnement du CSGR-IA.

Dimension	Situation actuelle	Avec BantuVoice
Rôle institutionnel	CSGR-IA : rôle consultatif Peu de productions tangibles	Producteur de corpus scientifiques Livrables mesurables et publiables
Positionnement continental	Malakshane (Nigeria/Afrique du Sud) ALL Lab (panafricain) Aucun acteur CEMAC	CSGR-IA = référence NLP Afrique centrale Fenêtre ouverte maintenant
Attractivité financière	Financements limités aux projets consultatifs locaux	UNESCO, AFD, Fondation Ford Google.org, Meta AI for Good Financements grants internationaux
Visibilité scientifique	Présence limitée dans la recherche africaine en IA	Publications conjointes Partenariats académiques Conférences internationales

Le CSGR-IA a l'opportunité de devenir la première institution d'Afrique centrale à produire une infrastructure de données linguistiques souveraine. C'est un positionnement que personne d'autre dans la région ne peut occuper aujourd'hui.

03 LE PROJET BANTUVOICE — ARCHITECTURE TECHNIQUE

Pipeline en trois étapes complémentaires

L'architecture repose sur une combinaison d'automatisation et d'expertise humaine. Chaque étape est conçue pour être progressive, documentée et reproductible sur de nouvelles langues.

Étape	Composante	Rôle dans l'équipe	Output
01 Collecte	yt-dlp · Sources YouTube Archives orales locales Métadonnées structurées	Développement pipeline Indexation par langue → Profil : développeur	Audio brut indexé Fichiers + métadonnées Par langue / source
02 Transcription	Whisper large-v3 Alignement mot/horodatage Détection auto de langue	Paramétrage modèle Analyse du signal audio → Profil : traitement parole	Transcriptions brutes Paires audio-texte Alignées mot par mot

03 Validation	Interface web (React) Double annotation Protocole de qualité	Recrutement locuteurs Protocole scientifique → Profil : linguiste / pôle	Corpus validé Format Hugging Face Prêt à l'entraînement
--------------------------------	--	--	---

Source pilote : Dumwénu TV

La chaîne YouTube Dumwénu TV — dédiée à la préservation et valorisation des langues et cultures nationales du Gabon — constitue notre source pilote idéale. Contenu en qualité studio, structuré par langue : **Fang, Punu, Obamba, Massangu, Gisir, Téké**. Estimation : +300 heures d'audio exploitable disponibles immédiatement.

04 ORGANISATION — GROUPE DE TRAVAIL PROPOSÉ

Trois profils complémentaires, une équipe soudée

La force de BantuVoice est précisément que les compétences nécessaires sont déjà présentes au sein du pôle. Il ne s'agit pas de tout faire seul — il s'agit d'organiser ce que nous avons déjà.

Rôle	Profil idéal	Contributions clés	Disponibilité
Porteur technique & coordination	Gildas (développeur IA, projets ML actifs)	Pipeline collecte + interface Annotation MVP Coordination générale	Disponible Immédiat
Expert traitement de la parole	Aryad (calcul scientifique, analyse statistique)	Architecture signal audio Protocole scientifique Modélisation statistique	À confirmer Selon disponibilité
Membres du pôle volontaires	Profilés ouverts (linguistes, juristes, développeurs, etc.)	Validation linguistique Relectures scientifiques Réseau de locuteurs natifs	À identifier lors du meet
Supervision institutionnelle	M. Anguilet (Responsable pôle)	Validation stratégique Portage institutionnel Relations externes	Bénédiction accordée ✓

Mode de fonctionnement proposé

- **Autonomie par module** — Chaque membre prend en charge un aspect selon son expertise. Pas de dépendance bloquante entre les modules.
- **Documentation systématique** — Chaque décision technique et méthodologique est documentée. Le projet est reproductible sur d'autres langues par d'autres équipes.
- **Revues d'avancement régulières** — Points de synchronisation courts entre porteurs, compte-rendu partagé au pôle.
- **Open source par défaut** — Le code et les corpus (hors données sensibles) sont publiés en open source sous licence africaine souveraine.

05 ATTRACTIVITÉ INVESTISSEURS ÉTRANGERS

Pourquoi ce positionnement institutionnel ouvre des financements inaccessibles à une startup privée

Un projet porté par le CSGR-IA — institution publique gabonaise de recherche — présente un profil de risque et de souveraineté que les bailleurs de fonds internationaux privilégient activement dans leurs appels à projets Afrique.

Bailleur	Programme	Montant typique	Critère clé
UNESCO	Convention patrimoine culturel immatériel + Programme langues en danger	50 000–500 000 USD	Institution nationale + langues menacées
AFD / Institut Français	Innovation numérique Afrique Souveraineté des données	100 000–1 M EUR	Partenariat franco-africain Impact mesurable
Google.org / Meta AI for Good	AI for Social Good African Languages Initiative	100 000–500 000 USD	Open source Communauté locale
Fondation Ford / MacArthur	Digital Rights Africa Cultural Preservation	50 000–300 000 USD	ONG ou institution Souveraineté culturelle
Union Africaine / SMART Africa	Agenda numérique africain Souveraineté des données	Variable	Institution membre UA Impact continental

Un projet porté institutionnellement par le CSGR-IA peut cumuler plusieurs de ces financements simultanément — ce qu'une startup seule ne peut pas faire. C'est la différence entre 50 000 USD et 1 million USD de financement potentiel.

06 ROADMAP — JALONS CONCRETS

Jalon	Date	Objectif	Responsable
Kickoff groupe de travail	Juin 2026	Constitution de l'équipe au sein du pôle Validation de la roadmap Répartition des modules	Gildas + Aryad + pôle
MVP technique	Fin juillet 2026	Pipeline collecte + transcription fonctionnel sur Dumwénu TV 50 segments annotés Fang	Gildas + Aryad
Corpus pilote v1	Fin août 2026	50h audio annotées · 1 langue Documentation scientifique Dépôt Hugging Face	Groupe de travail pôle complet
Soumission bailleur	Sept – Oct 2026	Dossier UNESCO / AFD Rapport technique CSGR-IA Première publication	M. Anguilet + porteurs
Phase croissance	2027	6 langues gabonaises 500h de données API BantuVoice v1	Équipe élargie

07 APPEL À L'ACTION — CE QUE NOUS ATTENDONS DU PÔLE

Ce document n'est pas une demande de permission. La bénédiction est là. C'est une invitation à co-construire quelque chose de grand — ensemble, au sein du CSGR-IA.

Pour chaque membre du pôle

Lire ce document. Identifier dans quelle dimension tu peux contribuer (technique, linguistique, communautaire, stratégique). Signifier ton intérêt lors du prochain meet.

Pour les profils traitement de la parole / calcul scientifique

Rejoindre Aryad pour co-construire l'architecture scientifique et statistique du pipeline. C'est la colonne vertébrale méthodologique du projet.

Pour les profils développement

Contribuer à l'interface d'annotation et au pipeline de collecte. Stack : Python, Whisper, React, MongoDB. MVP cible : fin juillet 2026.

Pour les profils linguistique / culturel

Aider à définir le protocole de validation et identifier des locuteurs natifs dans nos réseaux respectifs pour les premières langues cibles.

Construisons BantuVoice ensemble.

La donnée linguistique africaine doit appartenir à l'Afrique. Le CSGR-IA a les moyens, la légitimité et les cerveaux pour le faire. Il manquait l'initiative. Elle est là.

Gildas & Aryad · Pôle Technique & Innovation · CSGR-IA · csgria.ga

Note stratégique interne — Pôle Technique & Innovation · CSGR-IA · Juin 2026